

误差理论与数据处理

1 随机误差与残余误差公式推导

1.1 测量误差、残余误差与平均值

设被测量真值为 X ，第 i 次测量值为 l_i ，随机误差为 $\delta_i = l_i - X$ 。若共有 n 次等精度测量，则算术平均值为 $\bar{x} = \frac{1}{n} \sum_{i=1}^n l_i$ 。残余误差通常取为测量值与算术平均值之差，即 $v_i = l_i - \bar{x}$ 。于是有

$$\sum_{i=1}^n v_i = \sum_{i=1}^n (l_i - \bar{x}) = \sum_{i=1}^n l_i - n\bar{x}.$$

若 $\bar{x}$ 由原始数据精确算出，满足 $n\bar{x} = \sum_{i=1}^n l_i$ ，所以

$$\sum_{i=1}^n v_i = 0.$$

这就是残余误差代数和为零的来源。

1.2 残余误差代数和的凑整校核

实际计算时， $\bar{x}$ 常常需要凑整。设精确平均值为 $\bar{x}_0$ ，凑整后的平均值为 $\bar{x}$ ，二者相差

$$\varepsilon = \bar{x} - \bar{x}_0, \quad \sum_{i=1}^n v_i = \sum_{i=1}^n (l_i - \bar{x}) = \sum_{i=1}^n l_i - n\bar{x} = n\bar{x}_0 - n\bar{x} = -n\varepsilon.$$

若平均值按末位单位 A 凑整，则 $|\varepsilon| \leq A/2$ 。因此 $|\sum_{i=1}^n v_i| = n|\varepsilon| \leq nA/2$ 。若 n 为偶数， $\sum v_i$ 的最大可能绝对值可达到 $nA/2$ ，故 $|\sum_{i=1}^n v_i| \leq nA/2$ ；若 n 为奇数， $\sum v_i$ 通常只能取末位单位 A 的整数倍，而 $nA/2$ 是半整数倍的 A ，所以最大不超过 $(n-1)A/2$ ，即

$$\left| \sum_{i=1}^n v_i \right| \leq \frac{n-1}{2} A = \left(\frac{n}{2} - 0.5 \right) A.$$

这就是偶数、奇数两个校核公式的来源。

1.3 真误差标准差公式

若真值 X 已知，随机误差为 $\delta_i = l_i - X$ 。等精度测量中，随机误差的数学期望为零，即

$$E(\delta) = 0.$$

标准差由方差开方得到：

$$\sigma = \sqrt{\text{Var}(\delta)} = \sqrt{E(\delta^2) - [E(\delta)]^2}.$$

由于 $E(\delta) = 0$ ，所以

$$\sigma = \sqrt{E(\delta^2)}.$$

用有限次测量的平均平方误差代替数学期望，有

$$\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n \delta_i^2}.$$

该式适用于真值已知或可认为已知的情形。

1.4 贝塞尔公式推导

真值未知时，不能直接计算 $\delta_i = l_i - X$ ，只能使用残余误差

$$v_i = l_i - \bar{x}.$$

由

$$l_i - X = (l_i - \bar{x}) + (\bar{x} - X) = v_i + (\bar{x} - X)$$

得

$$\begin{aligned} \sum_{i=1}^n (l_i - X)^2 &= \sum_{i=1}^n [v_i + (\bar{x} - X)]^2 \\ &= \sum_{i=1}^n v_i^2 + 2(\bar{x} - X) \sum_{i=1}^n v_i + n(\bar{x} - X)^2. \end{aligned}$$

由于 $\sum v_i = 0$ ，中间项消失，因此

$$\sum_{i=1}^n (l_i - X)^2 = \sum_{i=1}^n v_i^2 + n(\bar{x} - X)^2.$$

对两边取数学期望。因为 $E[(l_i - X)^2] = \sigma^2$ ，所以

$$E \left[\sum_{i=1}^n (l_i - X)^2 \right] = n\sigma^2.$$

又因为

$$\text{Var}(\bar{x}) = \frac{\sigma^2}{n},$$

所以

$$E[n(\bar{x} - X)^2] = n\text{Var}(\bar{x}) = \sigma^2.$$

因此

$$n\sigma^2 = E \left(\sum_{i=1}^n v_i^2 \right) + \sigma^2,$$

即

$$E \left(\sum_{i=1}^n v_i^2 \right) = (n-1)\sigma^2.$$

于是得到无偏估计式

$$s^2 = \frac{\sum_{i=1}^n v_i^2}{n-1}, \quad s = \sqrt{\frac{\sum_{i=1}^n v_i^2}{n-1}}.$$

这就是贝塞尔公式。分母不是 n ，而是 $n-1$ ，原因是平均值 $\bar{x}$ 已由数据估计出来，残余误差满足 $\sum v_i = 0$ ，只有 $n-1$ 个独立信息量。

1.5 算术平均值标准差推导

设 $l_1, l_2, \dots, l_n$ 相互独立, 且方差均为 σ^2 。算术平均值为

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n l_i.$$

根据方差性质, 常数可以平方提出, 独立变量和的方差等于方差之和, 所以

$$\text{Var}(\bar{x}) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n l_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(l_i) = \frac{\sigma^2}{n}.$$

故算术平均值标准差为

$$\sigma_{\bar{x}} = \sqrt{\text{Var}(\bar{x})} = \frac{\sigma}{\sqrt{n}}.$$

用贝塞尔公式估计 σ , 可得

$$\sigma_{\bar{x}} = \sqrt{\frac{\sum_{i=1}^n v_i^2}{n(n-1)}}.$$

1.6 或然误差与平均误差系数来源

若随机误差服从正态分布 $N(0, \sigma^2)$, 则误差落在 $[-\rho, \rho]$ 内的概率为 $1/2$ 时, ρ 称为或然误差。令 $Z = \delta/\sigma$, 则 $P(-\rho \leq \delta \leq \rho) = P(-\rho/\sigma \leq Z \leq \rho/\sigma) = 1/2$ 。查标准正态分布表得 $\rho/\sigma = 0.6745$, 工程计算中常取 $0.6745 \approx 2/3$, 于是

$$\rho \approx \frac{2}{3}\sigma = \frac{2}{3}\sqrt{\frac{\sum_{i=1}^n v_i^2}{n-1}}.$$

平均误差常指绝对误差的数学期望。若 $\delta \sim N(0, \sigma^2)$, 则

$$\begin{aligned} \theta = E|\delta| &= \int_{-\infty}^{+\infty} |x| \frac{1}{\sigma\sqrt{2\pi}} e^{-x^2/(2\sigma^2)} dx \\ &= 2 \int_0^{+\infty} x \frac{1}{\sigma\sqrt{2\pi}} e^{-x^2/(2\sigma^2)} dx \\ &= \sigma \sqrt{\frac{2}{\pi}} \approx 0.7979\sigma \approx \frac{4}{5}\sigma. \end{aligned}$$

故有

$$\theta \approx \frac{4}{5}\sqrt{\frac{\sum_{i=1}^n v_i^2}{n-1}}.$$

算术平均值的或然误差与平均误差分别为

$$R = \frac{\rho}{\sqrt{n}}, \quad T = \frac{\theta}{\sqrt{n}}.$$

代入上式, 得到

$$R = \frac{2}{3}\sqrt{\frac{\sum v_i^2}{n(n-1)}}, \quad T = \frac{4}{5}\sqrt{\frac{\sum v_i^2}{n(n-1)}}.$$

1.7 别捷尔斯法公式推导

正态分布下，真误差的平均绝对值满足

$$E|\delta| = \sigma\sqrt{\frac{2}{\pi}}.$$

若使用残余误差 $v_i = l_i - \bar{x}$ ，则 v_i 的方差不是 σ^2 ，而是

$$\text{Var}(v_i) = \text{Var}(l_i - \bar{x}) = \sigma^2 \left(1 - \frac{1}{n}\right) = \frac{n-1}{n}\sigma^2.$$

因此可近似认为

$$E|v_i| \approx \sqrt{\frac{n-1}{n}}\sigma\sqrt{\frac{2}{\pi}}.$$

将 $E|v_i|$ 用样本平均值 $\frac{1}{n}\sum |v_i|$ 代替，得

$$\frac{1}{n}\sum_{i=1}^n |v_i| \approx \sqrt{\frac{n-1}{n}}\sigma\sqrt{\frac{2}{\pi}}.$$

解出 σ ：

$$\sigma \approx \sqrt{\frac{\pi}{2}}\sqrt{\frac{n}{n-1}}\frac{1}{n}\sum_{i=1}^n |v_i| = \sqrt{\frac{\pi}{2}}\frac{\sum_{i=1}^n |v_i|}{\sqrt{n(n-1)}}.$$

由于 $\sqrt{\pi/2} = 1.253\dots$ ，所以

$$\sigma = 1.253\frac{\sum_{i=1}^n |v_i|}{\sqrt{n(n-1)}}.$$

2 不等精度测量公式推导

2.1 权与方差倒数成正比的推导

设有 m 个独立测量结果 $x_1, x_2, \dots, x_m$ ，它们都测量同一个真值 X ，且

$$E(x_i) = X, \quad \text{Var}(x_i) = \sigma_i^2.$$

构造线性无偏估计

$$\hat{X} = \sum_{i=1}^m a_i x_i.$$

无偏条件为

$$E(\hat{X}) = \sum_{i=1}^m a_i E(x_i) = X \sum_{i=1}^m a_i = X,$$

所以必须满足

$$\sum_{i=1}^m a_i = 1.$$

由于各测量结果独立，估计量方差为

$$\text{Var}(\hat{X}) = \sum_{i=1}^m a_i^2 \sigma_i^2.$$

为了让估计最可靠，应在约束 $\sum a_i = 1$ 下使方差最小。构造拉格朗日函数

$$\Phi = \sum_{i=1}^m a_i^2 \sigma_i^2 - \lambda \left(\sum_{i=1}^m a_i - 1 \right).$$

对 a_i 求偏导并令其为零：

$$\frac{\partial \Phi}{\partial a_i} = 2a_i \sigma_i^2 - \lambda = 0.$$

所以

$$a_i = \frac{\lambda}{2\sigma_i^2}.$$

代入 $\sum a_i = 1$, 得

$$\frac{\lambda}{2} \sum_{i=1}^m \frac{1}{\sigma_i^2} = 1, \quad \frac{\lambda}{2} = \frac{1}{\sum_{i=1}^m 1/\sigma_i^2}.$$

于是

$$a_i = \frac{1/\sigma_i^2}{\sum_{j=1}^m 1/\sigma_j^2}.$$

这说明权应与方差成反比, 即

$$p_i \propto \frac{1}{\sigma_i^2}.$$

如果 x_i 本身是第 i 组测量的平均值, 则

$$p_i \propto \frac{1}{\sigma_{\bar{x}_i}^2},$$

即

$$p_1 : p_2 : \cdots : p_m = \frac{1}{\sigma_{\bar{x}_1}^2} : \frac{1}{\sigma_{\bar{x}_2}^2} : \cdots : \frac{1}{\sigma_{\bar{x}_m}^2}.$$

2.2 加权算术平均值推导

由上节得到

$$\hat{X} = \sum_{i=1}^m a_i x_i, \quad a_i = \frac{p_i}{\sum_{j=1}^m p_j}.$$

因此

$$\bar{x} = \hat{X} = \frac{\sum_{i=1}^m p_i x_i}{\sum_{i=1}^m p_i}.$$

为了减小数字运算量, 常引入接近各 x_i 的辅助值 x_0 。因为

$$x_i = x_0 + (x_i - x_0),$$

所以

$$\begin{aligned} \bar{x} &= \frac{\sum_{i=1}^m p_i [x_0 + (x_i - x_0)]}{\sum_{i=1}^m p_i} \\ &= \frac{x_0 \sum_{i=1}^m p_i + \sum_{i=1}^m p_i (x_i - x_0)}{\sum_{i=1}^m p_i} \\ &= x_0 + \frac{\sum_{i=1}^m p_i (x_i - x_0)}{\sum_{i=1}^m p_i}. \end{aligned}$$

这就是加权平均值的常用计算形式。

2.3 加权平均值标准差推导

若权的定义采用

$$p_i = \frac{\sigma_0^2}{\sigma_i^2},$$

其中 σ_0 为单位权标准差, 则

$$\sigma_i^2 = \frac{\sigma_0^2}{p_i}.$$

加权平均值为

$$\bar{x} = \sum_{i=1}^m \frac{p_i}{\sum p_i} x_i.$$

由于各 x_i 独立, 故

$$\text{Var}(\bar{x}) = \sum_{i=1}^m \left(\frac{p_i}{\sum p_i} \right)^2 \text{Var}(x_i) = \frac{\sigma_0^2}{(\sum p_i)^2} \sum_{i=1}^m p_i = \frac{\sigma_0^2}{\sum_{i=1}^m p_i}.$$

所以

$$\sigma_{\bar{x}} = \frac{\sigma_0}{\sqrt{\sum_{i=1}^m p_i}}.$$

若 σ_0 未知, 用加权残差估计单位权方差:

$$s_0^2 = \frac{\sum_{i=1}^m p_i v_i^2}{m-1}, \quad v_i = x_i - \bar{x}.$$

这是因为只估计了一个未知量 X , 自由度为 $m-1$ 。代入得

$$\sigma_{\bar{x}} = \frac{s_0}{\sqrt{\sum p_i}} = \sqrt{\frac{\sum_{i=1}^m p_i v_i^2}{(m-1) \sum_{i=1}^m p_i}}.$$

3 常见误差分布标准差推导

3.1 统一思路

若误差 δ 的概率密度为 $f(\delta)$, 则均值和方差为

$$\mu = E(\delta) = \int \delta f(\delta) d\delta, \quad \sigma^2 = \text{Var}(\delta) = \int (\delta - \mu)^2 f(\delta) d\delta.$$

若分布关于零点对称, 则 $\mu = 0$, 此时

$$\sigma^2 = \int \delta^2 f(\delta) d\delta.$$

3.2 均匀分布

均匀分布为

$$f(\delta) = \frac{1}{2a}, \quad -a \leq \delta \leq a.$$

该分布关于零点对称, 故 $\mu = 0$ 。于是

$$\sigma^2 = \int_{-a}^a \delta^2 \frac{1}{2a} d\delta = \frac{1}{2a} \left[\frac{\delta^3}{3} \right]_{-a}^a = \frac{a^2}{3}, \quad \sigma = \frac{a}{\sqrt{3}}.$$

3.3 反正弦分布

反正弦分布为

$$f(\delta) = \frac{1}{\pi \sqrt{a^2 - \delta^2}}, \quad |\delta| < a.$$

该分布关于零点对称。令 $\delta = a \sin \theta$, 则 $d\delta = a \cos \theta d\theta$, $\sqrt{a^2 - \delta^2} = a \cos \theta$ 。当 δ 从 $-a$ 到 a 时, θ 从 $-\pi/2$ 到 $\pi/2$ 。因此

$$\sigma^2 = \int_{-a}^a \delta^2 \frac{1}{\pi \sqrt{a^2 - \delta^2}} d\delta = \frac{1}{\pi} \int_{-\pi/2}^{\pi/2} a^2 \sin^2 \theta d\theta = \frac{a^2}{2}, \quad \sigma = \frac{a}{\sqrt{2}}.$$

3.4 三角分布

三角分布为

$$f(\delta) = \begin{cases} \frac{a+\delta}{a^2}, & -a \leq \delta < 0, \\ \frac{a-\delta}{a^2}, & 0 \leq \delta \leq a. \end{cases}$$

它关于零点对称，因此均值为零。方差为

$$\sigma^2 = 2 \int_0^a \delta^2 \frac{a-\delta}{a^2} d\delta = \frac{2}{a^2} \int_0^a (a\delta^2 - \delta^3) d\delta = \frac{a^2}{6}, \quad \sigma = \frac{a}{\sqrt{6}}.$$

3.5 直角分布

直角分布为

$$f(\delta) = \frac{\delta+a}{2a^2}, \quad -a \leq \delta \leq a.$$

该分布不关于零点对称，必须先求均值：

$$\mu = \int_{-a}^a \delta \frac{\delta+a}{2a^2} d\delta = \frac{1}{2a^2} \int_{-a}^a (\delta^2 + a\delta) d\delta = \frac{a}{3}.$$

再求二阶原点矩：

$$E(\delta^2) = \int_{-a}^a \delta^2 \frac{\delta+a}{2a^2} d\delta = \frac{1}{2a^2} \int_{-a}^a (\delta^3 + a\delta^2) d\delta = \frac{a^2}{3}.$$

于是

$$\sigma^2 = E(\delta^2) - \mu^2 = \frac{a^2}{3} - \frac{a^2}{9} = \frac{2a^2}{9}, \quad \sigma = \frac{\sqrt{2}a}{3}.$$

3.6 椭圆分布

椭圆分布为

$$f(\delta) = \frac{2}{\pi a^2} \sqrt{a^2 - \delta^2}, \quad |\delta| \leq a.$$

它关于零点对称。令 $\delta = a \sin \theta$ ，则

$$\sigma^2 = \int_{-a}^a \delta^2 \frac{2}{\pi a^2} \sqrt{a^2 - \delta^2} d\delta = \frac{2a^2}{\pi} \int_{-\pi/2}^{\pi/2} \sin^2 \theta \cos^2 \theta d\theta.$$

由 $\sin^2 \theta \cos^2 \theta = \frac{1}{8}(1 - \cos 4\theta)$ ，得

$$\int_{-\pi/2}^{\pi/2} \sin^2 \theta \cos^2 \theta d\theta = \frac{\pi}{8}.$$

因此

$$\sigma^2 = \frac{2a^2}{\pi} \cdot \frac{\pi}{8} = \frac{a^2}{4}, \quad \sigma = \frac{a}{2}.$$

3.7 双三角分布

双三角分布为

$$f(\delta) = \frac{|\delta|}{a^2}, \quad |\delta| \leq a.$$

它关于零点对称。方差为

$$\sigma^2 = 2 \int_0^a \delta^2 \frac{\delta}{a^2} d\delta = \frac{2}{a^2} \int_0^a \delta^3 d\delta = \frac{a^2}{2}, \quad \sigma = \frac{a}{\sqrt{2}}.$$

4 系统误差与粗大误差判别公式说明

4.1 两个平均值比较公式

设两组测量平均值分别为 $\bar{x}_i$ 和 $\bar{x}_j$ ，其标准差分别为 σ_i 和 σ_j ，并假定二者独立。考虑差值

$$D = \bar{x}_i - \bar{x}_j.$$

若两组数据之间不存在显著系统差异，则 D 的理论均值应为零。由独立变量方差相加得

$$\text{Var}(D) = \text{Var}(\bar{x}_i) + \text{Var}(\bar{x}_j) = \sigma_i^2 + \sigma_j^2.$$

因此差值的标准差为

$$\sigma_D = \sqrt{\sigma_i^2 + \sigma_j^2}.$$

若采用约 2σ 的经验界限，则比较量为

$$|\bar{x}_i - \bar{x}_j| \quad \text{与} \quad 2\sqrt{\sigma_i^2 + \sigma_j^2}.$$

若差值超过该界限，通常认为两组平均值之间存在显著差异；若没有超过，则认为差异可由随机误差解释。

4.2 秩和检验大样本近似推导

将两组数据合并后按大小排序，并给出秩次。设第一组样本量为 n_1 ，第二组样本量为 n_2 ，第一组秩和为 T 。在无系统差异的原假设下，第一组相当于从 $1, 2, \dots, n_1 + n_2$ 这些秩次中随机抽取 n_1 个。

设总样本量

$$N = n_1 + n_2.$$

所有秩次的平均值为

$$\frac{1 + N}{2}.$$

故秩和的数学期望为

$$a = E(T) = n_1 \frac{N + 1}{2} = \frac{n_1(n_1 + n_2 + 1)}{2}.$$

不放回抽样秩和的方差为

$$\sigma_T^2 = \frac{n_1 n_2 (N + 1)}{12} = \frac{n_1 n_2 (n_1 + n_2 + 1)}{12}.$$

当 n_1, n_2 较大时，秩和近似服从正态分布，因此标准化统计量为

$$Z = \frac{T - a}{\sigma_T} = \frac{T - \frac{n_1(n_1 + n_2 + 1)}{2}}{\sqrt{\frac{n_1 n_2 (n_1 + n_2 + 1)}{12}}}.$$

若

$$|Z| > t_\alpha,$$

则认为两组数据的中心位置差异显著，从而可判断存在系统差异。

4.3 两样本 t 检验公式推导

设两组样本均值分别为 $\bar{x}, \bar{y}$, 样本容量分别为 n_x, n_y , 样本标准差分别为 σ_x, σ_y 。若认为两组总体方差相同, 则合并方差估计通常为

$$s_p^2 = \frac{n_x \sigma_x^2 + n_y \sigma_y^2}{n_x + n_y - 2}.$$

这里分母为 $n_x + n_y - 2$, 是因为两组数据各自估计了一个均值, 共损失两个自由度。

均值差的标准差为

$$s_{\bar{x}-\bar{y}} = s_p \sqrt{\frac{1}{n_x} + \frac{1}{n_y}} = s_p \sqrt{\frac{n_x + n_y}{n_x n_y}}.$$

所以

$$|t| = \frac{|\bar{x} - \bar{y}|}{s_p \sqrt{(n_x + n_y)/(n_x n_y)}} = |\bar{x} - \bar{y}| \sqrt{\frac{n_x n_y (n_x + n_y - 2)}{(n_x + n_y)(n_x \sigma_x^2 + n_y \sigma_y^2)}}.$$

若 $|t| \geq t_\alpha$, 则认为两组均值差异显著。

4.4 莱以特准则的概率依据

若误差服从正态分布, 则

$$P(|\delta| \leq 3\sigma) \approx 0.9973.$$

这说明正常随机误差落在 $[-3\sigma, 3\sigma]$ 外的概率约为 0.27%。所以若某个残余误差满足

$$|v_i| > 3\sigma,$$

则它很难仅由正常随机波动产生, 因而可怀疑为粗大误差。实际使用时, σ 常用贝塞尔公式估计:

$$\sigma = \sqrt{\frac{\sum_{i=1}^n v_i^2}{n-1}}.$$

4.5 罗曼诺夫斯基准则的留一思想

判断第 j 个观测值 x_j 是否异常时, 为避免异常值本身影响平均值, 常把它从样本中临时剔除, 用其余 $n-1$ 个数据计算平均值:

$$\bar{x}_{(-j)} = \frac{1}{n-1} \sum_{i=1, i \neq j}^n x_i.$$

再用其余数据估计标准差。因为剔除了一个可疑值, 还剩 $n-1$ 个数据, 并估计了一个平均值, 所以自由度为 $n-2$:

$$s_{(-j)} = \sqrt{\frac{\sum_{i=1}^n v_i^2}{n-2}}.$$

于是构造标准化偏离量

$$\frac{|x_j - \bar{x}_{(-j)}|}{s_{(-j)}} = \frac{\left| x_j - \frac{1}{n-1} \sum_{i=1, i \neq j}^n x_i \right|}{\sqrt{\frac{\sum_{i=1}^n v_i^2}{n-2}}}.$$

若该值超过临界值 $K(n, \alpha)$, 则判为粗大误差。

4.6 格罗布斯准则与狄克松准则的统计量含义

格罗布斯准则先将数据从小到大排列为

$$x_{(1)} \leq x_{(2)} \leq \cdots \leq x_{(n)}.$$

若怀疑最小值异常, 则考察

$$g_{(1)} = \frac{\bar{x} - x_{(1)}}{\sigma};$$

若怀疑最大值异常, 则考察

$$g_{(n)} = \frac{x_{(n)} - \bar{x}}{\sigma}.$$

其本质是把端点偏离平均值的距离用标准差标准化, 再与临界值 $g_0(n, \alpha)$ 比较。

狄克松准则不计算标准差, 而是用“可疑端点与邻近点的间隔”除以“样本总体跨度”或修正后的跨度。例如当 $n \leq 7$ 时, 最小端异常的统计量为

$$r_{10} = \frac{x_{(2)} - x_{(1)}}{x_{(n)} - x_{(1)}}.$$

若 $x_{(1)}$ 远离其他数据, 则 $x_{(2)} - x_{(1)}$ 大, r_{10} 也大。最大端异常时可写为

$$r_{10} = \frac{x_{(n)} - x_{(n-1)}}{x_{(n)} - x_{(1)}}.$$

样本量变大后, 分母需要排除一个或两个端点以降低另一端异常值的干扰, 因此出现 r_{11}, r_{21}, r_{22} 等不同形式。

5 误差合成与误差分配推导

5.1 函数标准差合成公式推导

设输入误差为随机量 Δx_i , 输出误差的一阶近似为

$$\Delta y = \sum_{i=1}^n a_i \Delta x_i, \quad a_i = \frac{\partial f}{\partial x_i}.$$

输出方差为

$$\sigma_y^2 = \text{Var}(\Delta y) = \text{Var}\left(\sum_{i=1}^n a_i \Delta x_i\right).$$

展开方差:

$$\text{Var}\left(\sum_{i=1}^n a_i \Delta x_i\right) = \sum_{i=1}^n a_i^2 \text{Var}(\Delta x_i) + 2 \sum_{1 \leq i < j \leq n} a_i a_j \text{Cov}(\Delta x_i, \Delta x_j).$$

令

$$\text{Var}(\Delta x_i) = \sigma_{x_i}^2, \quad \text{Cov}(\Delta x_i, \Delta x_j) = \rho_{ij} \sigma_{x_i} \sigma_{x_j},$$

其中 ρ_{ij} 为相关系数。代入得

$$\sigma_y^2 = \sum_{i=1}^n a_i^2 \sigma_{x_i}^2 + 2 \sum_{1 \leq i < j \leq n} a_i a_j \rho_{ij} \sigma_{x_i} \sigma_{x_j}.$$

再开方:

$$\sigma_y = \left[\sum_{i=1}^n \left(\frac{\partial f}{\partial x_i} \right)^2 \sigma_{x_i}^2 + 2 \sum_{1 \leq i < j \leq n} \frac{\partial f}{\partial x_i} \frac{\partial f}{\partial x_j} \rho_{ij} \sigma_{x_i} \sigma_{x_j} \right]^{1/2}.$$

5.2 等作用原则误差分配推导

设输出函数一阶误差为

$$\Delta y = \sum_{i=1}^n a_i \Delta x_i.$$

若各输入互不相关, 则

$$\sigma_y^2 = \sum_{i=1}^n a_i^2 \sigma_i^2.$$

等作用原则要求每个误差源对输出方差的贡献相等, 即

$$a_i^2 \sigma_i^2 = \frac{\sigma_y^2}{n}.$$

两边开方, 得

$$|a_i| \sigma_i = \frac{\sigma_y}{\sqrt{n}}.$$

若取 $a_i > 0$ 或用绝对值表示灵敏度, 则

$$\sigma_i = \frac{\sigma_y}{\sqrt{n}} \frac{1}{|a_i|} = \frac{\sigma_y}{\sqrt{n}} \frac{1}{|\partial f / \partial x_i|}.$$

同理, 对极限误差有

$$\delta_i = \frac{\delta}{\sqrt{n}} \frac{1}{|a_i|}.$$

6 不确定度合成公式推导

设测量结果由

$$y = f(x_1, x_2, \dots, x_N)$$

给出。对函数作一阶展开:

$$\Delta y \approx \sum_{i=1}^N \frac{\partial f}{\partial x_i} \Delta x_i.$$

令输入量的标准不确定度为 u_{x_i} , 灵敏系数为

$$c_i = \frac{\partial f}{\partial x_i}.$$

若各输入量独立, 则

$$u_c^2(y) = \sum_{i=1}^N c_i^2 u_{x_i}^2.$$

记每个输入量对输出量贡献的标准不确定度为

$$u_i = c_i u_{x_i},$$

则

$$u_c = \sqrt{\sum_{i=1}^N \left(\frac{\partial f}{\partial x_i} \right)^2 u_{x_i}^2} = \sqrt{\sum_{i=1}^N u_i^2}.$$

这与误差合成公式形式完全一致, 只是把标准差符号换成标准不确定度符号。

7 最小二乘法公式推导

7.1 线性误差方程

设有 n 个观测方程, t 个未知参数。写成矩阵形式为

$$L = AX + \varepsilon,$$

$$L = \begin{pmatrix} l_1 \\ l_2 \\ \vdots \\ l_n \end{pmatrix}, \quad X = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_t \end{pmatrix}, \quad A = (a_{ij})_{n \times t}.$$

用估计量 $\hat{X}$ 代替真参数后, 拟合值为 $A\hat{X}$, 残差向量为 $V = L - A\hat{X}$ 。

7.2 等精度最小二乘正规方程

等精度时, 各观测方程可靠程度相同, 应使残差平方和最小:

$$\Phi = V^T V = (L - A\hat{X})^T (L - A\hat{X}).$$

展开:

$$\Phi = L^T L - L^T A\hat{X} - \hat{X}^T A^T L + \hat{X}^T A^T A\hat{X}.$$

由于 $L^T A\hat{X}$ 是标量, 等于其转置 $\hat{X}^T A^T L$, 所以

$$\Phi = L^T L - 2\hat{X}^T A^T L + \hat{X}^T A^T A\hat{X}.$$

对 $\hat{X}$ 求导并令其为零:

$$\frac{\partial \Phi}{\partial \hat{X}} = -2A^T L + 2A^T A\hat{X} = 0.$$

故

$$A^T A\hat{X} = A^T L.$$

这就是正规方程。若 $A^T A$ 可逆, 则

$$\hat{X} = (A^T A)^{-1} A^T L.$$

记 $C = A^T A$, 则 $\hat{X} = C^{-1} A^T L$ 。

7.3 不等精度最小二乘正规方程

不等精度时, 各观测值的方差不同。方差小的观测值应有更大权重。设权阵为

$$P = \text{diag}(p_1, p_2, \dots, p_n) = \begin{bmatrix} p_1 & 0 & \cdots & 0 \\ 0 & p_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & p_n \end{bmatrix}.$$

此时应最小化加权残差平方和

$$\Phi = V^T P V = (L - A\hat{X})^T P (L - A\hat{X}).$$

展开并求导：

$$\begin{aligned}\Phi &= L^T PL - 2\hat{X}^T A^T PL + \hat{X}^T A^T PA \hat{X}, \\ \frac{\partial \Phi}{\partial \hat{X}} &= -2A^T PL + 2A^T PA \hat{X} = 0.\end{aligned}$$

于是

$$A^T PA \hat{X} = A^T PL.$$

若 $A^T PA$ 可逆，则

$$\hat{X} = (A^T PA)^{-1} A^T PL.$$

记 $C = A^T PA$ ，则 $\hat{X} = C^{-1} A^T PL$ 。等精度是 $P = I$ 的特殊情况。

7.4 单位权标准差与自由度

设共有 n 个观测方程、 t 个未知参数。最小二乘中， t 个参数由数据估计出来，因此残差的独立个数为

$$r = n - t.$$

这就是自由度。等精度时，单位权标准差估计为

$$\sigma_0 = \sqrt{\frac{V^T V}{n - t}} = \sqrt{\frac{\sum_{i=1}^n v_i^2}{n - t}}.$$

不等精度时，采用加权残差平方和：

$$\sigma_0 = \sqrt{\frac{V^T P V}{n - t}} = \sqrt{\frac{\sum_{i=1}^n p_i v_i^2}{n - t}}.$$

7.5 参数估计量标准差推导

在不等精度线性模型中，有

$$\hat{X} = (A^T PA)^{-1} A^T PL.$$

若观测误差协方差阵与权阵满足

$$\text{Cov}(L) = \sigma_0^2 P^{-1},$$

则估计量协方差阵为

$$\begin{aligned}\text{Cov}(\hat{X}) &= (A^T PA)^{-1} A^T P \text{Cov}(L) P A (A^T PA)^{-1} \\ &= (A^T PA)^{-1} A^T P (\sigma_0^2 P^{-1}) P A (A^T PA)^{-1} \\ &= \sigma_0^2 (A^T PA)^{-1}.\end{aligned}$$

设

$$(A^T PA)^{-1} = \begin{pmatrix} d_{11} & d_{12} & \cdots & d_{1t} \\ d_{21} & d_{22} & \cdots & d_{2t} \\ \vdots & \vdots & \ddots & \vdots \\ d_{t1} & d_{t2} & \cdots & d_{tt} \end{pmatrix}.$$

则第 i 个估计量的方差为

$$\sigma_{x_i}^2 = \sigma_0^2 d_{ii}.$$

所以

$$\sigma_{x_i} = \sigma_0 \sqrt{d_{ii}}, \quad i = 1, 2, \dots, t.$$

8 一元线性回归公式推导

8.1 最小二乘目标函数

设一元线性回归模型为

$$\hat{y}_t = b_0 + bx_t, \quad t = 1, 2, \dots, N.$$

残差为

$$e_t = y_t - \hat{y}_t = y_t - b_0 - bx_t.$$

最小二乘法要求残差平方和最小：

$$Q(b_0, b) = \sum_{t=1}^N (y_t - b_0 - bx_t)^2.$$

8.2 回归系数与截距推导

对 b_0 和 b 分别求偏导：

$$\begin{aligned} \frac{\partial Q}{\partial b_0} &= -2 \sum_{t=1}^N (y_t - b_0 - bx_t) = 0, \\ \frac{\partial Q}{\partial b} &= -2 \sum_{t=1}^N x_t (y_t - b_0 - bx_t) = 0. \end{aligned}$$

化简第一式：

$$\sum_{t=1}^N y_t - Nb_0 - b \sum_{t=1}^N x_t = 0.$$

两边除以 N ，得

$$\bar{y} - b_0 - b\bar{x} = 0, \quad b_0 = \bar{y} - b\bar{x}.$$

代入第二个正规方程：

$$\sum_{t=1}^N x_t [y_t - (\bar{y} - b\bar{x}) - bx_t] = 0.$$

即

$$\sum_{t=1}^N x_t (y_t - \bar{y}) - b \sum_{t=1}^N x_t (x_t - \bar{x}) = 0.$$

注意

$$\sum_{t=1}^N x_t (y_t - \bar{y}) = \sum_{t=1}^N (x_t - \bar{x})(y_t - \bar{y}) = l_{xy},$$

以及

$$\sum_{t=1}^N x_t (x_t - \bar{x}) = \sum_{t=1}^N (x_t - \bar{x})^2 = l_{xx}.$$

所以

$$l_{xy} - bl_{xx} = 0, \quad b = \frac{l_{xy}}{l_{xx}}.$$

再代回得到

$$b_0 = \bar{y} - b\bar{x}.$$

8.3 离差平方和恒等式

自变量离差平方和为

$$l_{xx} = \sum_{t=1}^N (x_t - \bar{x})^2.$$

展开:

$$\begin{aligned} l_{xx} &= \sum_{t=1}^N (x_t^2 - 2x_t\bar{x} + \bar{x}^2) \\ &= \sum_{t=1}^N x_t^2 - 2\bar{x} \sum_{t=1}^N x_t + N\bar{x}^2. \end{aligned}$$

由于 $\sum x_t = N\bar{x}$, 所以

$$l_{xx} = \sum_{t=1}^N x_t^2 - 2N\bar{x}^2 + N\bar{x}^2 = \sum_{t=1}^N x_t^2 - N\bar{x}^2.$$

又

$$N\bar{x}^2 = N \left(\frac{1}{N} \sum_{t=1}^N x_t \right)^2 = \frac{1}{N} \left(\sum_{t=1}^N x_t \right)^2.$$

故

$$l_{xx} = \sum_{t=1}^N x_t^2 - \frac{1}{N} \left(\sum_{t=1}^N x_t \right)^2.$$

同理可得

$$l_{yy} = \sum_{t=1}^N y_t^2 - \frac{1}{N} \left(\sum_{t=1}^N y_t \right)^2.$$

8.4 离差积和恒等式

离差积和为

$$l_{xy} = \sum_{t=1}^N (x_t - \bar{x})(y_t - \bar{y}).$$

展开:

$$\begin{aligned} l_{xy} &= \sum_{t=1}^N (x_t y_t - x_t \bar{y} - \bar{x} y_t + \bar{x} \bar{y}) \\ &= \sum_{t=1}^N x_t y_t - \bar{y} \sum_{t=1}^N x_t - \bar{x} \sum_{t=1}^N y_t + N\bar{x} \bar{y}. \end{aligned}$$

由 $\sum x_t = N\bar{x}$ 、 $\sum y_t = N\bar{y}$, 得

$$l_{xy} = \sum_{t=1}^N x_t y_t - N\bar{x} \bar{y}.$$

而

$$N\bar{x} \bar{y} = \frac{1}{N} \left(\sum_{t=1}^N x_t \right) \left(\sum_{t=1}^N y_t \right).$$

所以

$$l_{xy} = \sum_{t=1}^N x_t y_t - \frac{1}{N} \left(\sum_{t=1}^N x_t \right) \left(\sum_{t=1}^N y_t \right).$$

8.5 平方和分解推导

总离差平方和为

$$S = \sum_{t=1}^N (y_t - \bar{y})^2 = l_{yy}.$$

将 $y_t - \bar{y}$ 分解为

$$y_t - \bar{y} = (\hat{y}_t - \bar{y}) + (y_t - \hat{y}_t).$$

于是

$$\begin{aligned} S &= \sum_{t=1}^N [(\hat{y}_t - \bar{y}) + (y_t - \hat{y}_t)]^2 \\ &= \sum_{t=1}^N (\hat{y}_t - \bar{y})^2 + \sum_{t=1}^N (y_t - \hat{y}_t)^2 + 2 \sum_{t=1}^N (\hat{y}_t - \bar{y})(y_t - \hat{y}_t). \end{aligned}$$

最小二乘回归中，残差与拟合值正交，因此

$$\sum_{t=1}^N (\hat{y}_t - \bar{y})(y_t - \hat{y}_t) = 0.$$

所以

$$S = U + Q,$$

其中

$$U = \sum_{t=1}^N (\hat{y}_t - \bar{y})^2, \quad Q = \sum_{t=1}^N (y_t - \hat{y}_t)^2.$$

由于

$$\hat{y}_t - \bar{y} = b_0 + bx_t - \bar{y} = b(x_t - \bar{x}),$$

因此

$$U = \sum_{t=1}^N b^2 (x_t - \bar{x})^2 = b^2 l_{xx}.$$

又 $b = l_{xy}/l_{xx}$ ，故

$$U = b^2 l_{xx} = b l_{xy}.$$

因此

$$Q = S - U = l_{yy} - b l_{xy}.$$

8.6 回归方差分析与 F 统计量

一元线性回归中，回归平方和对应一个回归系数 b ，故自由度为 $\nu_U = 1$ 。总平方和自由度为 $N - 1$ ，因为估计了一个总体均值 $\bar{y}$ 。残差平方和在估计 b_0, b 两个参数后还剩 $\nu_Q = N - 2$ 个自由度。于是回归均方和残差均方分别为

$$M_U = \frac{U}{\nu_U} = \frac{U}{1}, \quad M_Q = \frac{Q}{\nu_Q} = \frac{Q}{N - 2}.$$